

UNIVERSIDAD MAYOR REAL Y PONTIFICIAL DE SAN FRANCISCO XAVIER DE CHUQUISACA

FACULTAD DE TECNOLOGIA

INGENIERIA DE SISTEMAS, INGENIERIA EN CIENCIAS DE LA COMPUTACION E
INGENIERIA EN DISEÑO Y ANIMACION DIGITAL

SIS420, COM300 – INTELIGENCIA ARTIFICIAL I

MACHINE LEARNING

ING. CARLOS WALTER PACHECO LORA PH.D.


SUCRE - BOLIVIA, 2024

¿Qué es Machine Learning?

“El machine learning (aprendizaje automático) es una subcategoría de la inteligencia artificial (IA) que se centra en el desarrollo de algoritmos y modelos que permiten a las máquinas aprender patrones a partir de datos y hacer predicciones o tomar decisiones sin ser explícitamente programadas para cada tarea”

Permite:

- Aprender de los datos
- No programación explícita
- Descubrimiento de patrones ocultos
- Toma de decisiones basada en los datos




Programación tradicional VS Machine Learning


Programación tradicional



Machine Learning



Multidisciplinar



Ejemplo: SPAM




5

Ejemplo de aplicación: Detección de fraude en tarjetas de crédito



6

Ejemplo de aplicación: Recomendaciones de compra




7

Otros ejemplos de aplicación

- Anuncios orientados en aplicaciones móviles
- Análisis de sentimiento en las redes sociales
- Monitorización climática para detectar patrones estacionales
- Detección de patrones en la lucha contra el crimen
- Aplicación en sanidad
- Entre muchas otras mas ...

8

Tipos de aprendizaje



9


Conjunto de datos

Datasets:

- Conjunto de datos,
- Soporte digital,
- Varios formatos
- Similar a una o mas tablas de una base de datos,
- Almacenan características y etiquetas

Presentación y formato:

- Archivos de texto
- Hojas de calculo
- Carpeta con imágenes
- Carpeta con sonidos
- Muchos otros.



10

Diferencias entre inteligencia artificial, Machine Learning y Deep Learning

Inteligencia Artificial (IA), Machine Learning y Deep Learning conceptos relacionados, pero tedioso vislumbrar la diferencia entre ellos.

Inteligencia artificial concepto amplio, objetivo es que las máquinas sean capaces de realizar tareas de la misma forma en que las haría un ser humano. Esto se desarrolla a través de la ejecución de reglas previamente programadas. Se definió en la Conferencia de Inteligencia Artificial de Dartmouth (1956) como “todos los aspectos del aprendizaje o cualquier otra característica de la inteligencia que puede, en principio, ser precisamente descrita de tal forma que una máquina pueda realizarla”. Ya desde principios de siglo XX tenemos algunos ejemplos de ello en pioneros como Alan Turing quien descifró la máquina Enigma en lo que fue la primera aparición de lo que hoy llamaríamos las redes neuronales.

Aprendizaje automático (ML) rama de la IA, “el conjunto de métodos que puede detectar patrones automáticamente en un conjunto de datos y usarlos para predecir datos futuros, o para llevar a cabo otro tipo de decisiones en entornos de incertidumbre”.

Deep Learning o aprendizaje profundo es una rama del Machine Learning, definido en su aspecto más básico, se puede explicar como un sistema de probabilidad que permite a modelos computacionales que están compuestos de múltiples capas de procesamiento aprender sobre datos con múltiples niveles de abstracción.

Aplicaciones y herramientas para machine learning

Aprendizaje supervisado

- Regresión
- Clasificación

13

Regresión

Objetivo:

Predecir un valor numérico



14


Ejemplos de aplicación de la regresión

- Pronóstico de ventas
- Valor de cliente a futuro
- Predecir cantidad de lluvia
- Muchas otras mas ...

15

Clasificación

Objetivo: Predecir una categoría



16

Ejemplos de clasificación

- Propensión de compra
- Clasificación de un tumor como benignos o malignos (Binaria)
- Determinación de riesgo (alto, medio, bajo) para una solicitud de préstamo.
- Sentimiento en las redes sociales como positivo, negativo o neutro
- Entre muchos otros mas ...

17

Aplicaciones: Tipologías de problemas


Objetivo: Descripción

- ✓ Segmentación ■ Clustering
- ✓ Asociación ■ Ofertas productos cruzados

Modelización Descriptiva
Análisis No Supervisado

AGRUPACIÓN

PATRONES




Objetivo: Predicción

- ✓ Estimación ■ Pronóstico de Ventas
- ✓ Estimación ■ Valor de cliente a futuro
- ✓ Clasificación ■ Propensión a compra
- ✓ Clasificación ■ Alto / Bajo valor de Cliente

Modelización Predictiva
Análisis Supervisado

RANKING

DECISIÓN



18

Terminología básica de Machine Learning

Etiqueta (Label), lo que se intenta predecir con un modelo.

Variable de entrada (Feature) (“característica” o “variable” de un ejemplo o dato de entrada).

Modelo (Model) define la relación entre features y labels y tiene dos fases claramente diferenciadas:

- **Fase de entrenamiento o aprendizaje (training)**, cuando se crea o se “aprende” el modelo, mostrándole los ejemplos de entrada que se tienen etiquetados; de esta manera se consigue que el modelo aprenda iterativamente las relaciones entre las features y labels de los ejemplos.
- **Fase de inferencia o predicción (inference)**, proceso de hacer predicciones mediante la aplicación del modelo ya entrenado a ejemplos no etiquetados.

Modelo que expresa una relación lineal entre features y labels

$$y=wx+b$$

y es la label o etiqueta de un ejemplo de entrada.

x la feature de ese ejemplo de entrada.

w es la pendiente de la recta y que en general le llamaremos “peso” (o weight en inglés) y es uno de los dos parámetros que se tienen que aprender el modelo durante el proceso de entrenamiento para poder usarlo luego para inferencia.

b es el punto de intersección de la recta en el eje y que llamamos “sesgo” (o bias en inglés). Este es el otro de los parámetros que deben ser aprendidos por el modelo.

Formulación

Aunque en este modelo simple que hemos representado solo tenemos una *feature* de entrada, en el caso de Deep Learning veremos que tenemos muchas variables de entrada, cada una con su peso w_i . Por ejemplo, un modelo basado en tres *features* (x_1, x_2, x_3) puede expresarse de la siguiente manera:

$$y = w_1x_1 + w_2x_2 + w_3x_3 + b$$

O, de manera más general, se puede expresar como:

$$y = \sum_i w_i x_i + b$$


que expresa el sumatorio del producto escalar entre los dos vectores (X y W) y luego suma el sesgo.

21

Regresión


- Aprendizaje supervisado

- Regresión -> Valores continuos
- Clasificación -> Valores discretos



22

Modelo de regresión lineal simple: Predicción del precio de una vivienda



Aprendizaje supervisado:

Dado un conjunto de datos ejemplo
correctos

Problema de regresión:

Predice una salida con un valor real


Conjunto de datos de entrenamiento

Notación:


- m = Numero de ejemplos de entrenamiento.
- x 's = variable "entradas" / características
- y 's = variable "salida" / variable "objetivo"
- (x, y) = un ejemplo de entrenamiento
- $(x^{(i)}, y^{(i)})$ = iesimo ejemplo de entrenamiento

Tamaño en pies ² (x)	Precio (\$) en 1000's (y)
2104	460
1416	232
1534	315
852	178
...	...

Hipotesis (H)






Como representar h ?



Regresión lineal con una variable.
Regresión lineal univariable.

Análisis de la hipótesis en relación a posibles valores de θ_0 y θ_1



Función de costo (J)

Si la hipótesis es: $h_{\theta}(x) = \theta_0 + \theta_1 x$

Como calculamos θ_0, θ_1 ?

Se busca θ_0, θ_1 de manera que se $h(\theta)$ sea cercano a y con los m datos de entrenamiento x, y .

Se utiliza la formula de diferencia de cuadrados:

$$J(\theta_0, \theta_1) = \frac{1}{2m} \sum_{i=1}^m (h_{\theta}(x^{(i)}) - y^{(i)})^2$$

Tamaño en pies ² (x)	Precio (\$) en 1000's (y)
2104	460
1416	232
1534	315
852	178
...	...

27

Formulas:

Hipotesis:

- $h_{\theta}(x) = \theta_0 + \theta_1 x$
- Si $\theta_0 = 0$; $h_{\theta}(x) = \theta_1 x$ (Simplificado)

Parámetros:

- θ_0, θ_1

Función de costo:


- $J(\theta_0, \theta_1) = \frac{1}{2m} \sum_{i=1}^m (h_{\theta}(x^{(i)}) - y^{(i)})^2$

Objetivo:


- Minimizar $J(\theta_0, \theta_1)$

28

Relación graficas de hipótesis y costo



Gráfica de costo, considerando (θ_0, θ_1)



Descenso por el gradiente

Dada la función $J(\theta_0, \theta_1)$, se quiere minimizar $\min_{\theta_0, \theta_1} J(\theta_0, \theta_1)$

Estrategia:

- Se asignan valores iniciales a θ_0, θ_1
- Se realizan y almacena cambios en θ_0, θ_1
- Hasta alcanzar un mínimo para $J(\theta_0, \theta_1)$


Formula:

$$\theta_0 := \theta_0 - \alpha \frac{1}{m} \sum_{i=1}^m (h_{\theta}(x^{(i)}) - y^{(i)})$$


$$\theta_1 := \theta_1 - \alpha \frac{1}{m} \sum_{i=1}^m (h_{\theta}(x^{(i)}) - y^{(i)}) \cdot x^{(i)}$$

31

Gráfico del descenso por el gradiente



Camino alternativo en el descenso por el gradiente



Algoritmo del descenso por el gradiente

Repetir hasta que converja (Para $j = 0$ y $j = 1$) {

$$\theta_j := \theta_j - \alpha \frac{\partial}{\partial \theta_j} J(\theta_0, \theta_1)$$

}

Importante:

Forma correcta de actualización:

$$\text{temp0} := \theta_0 - \alpha \frac{\partial}{\partial \theta_0} J(\theta_0, \theta_1)$$

$$\text{temp1} := \theta_1 - \alpha \frac{\partial}{\partial \theta_1} J(\theta_0, \theta_1)$$

$$\theta_0 := \text{temp0}$$

$$\theta_1 := \text{temp1}$$

Forma incorrecta de actualización:

$$\text{temp0} := \theta_0 - \alpha \frac{\partial}{\partial \theta_0} J(\theta_0, \theta_1)$$

$$\theta_0 := \text{temp0}$$

$$\text{temp1} := \theta_1 - \alpha \frac{\partial}{\partial \theta_1} J(\theta_0, \theta_1)$$

$$\theta_1 := \text{temp1}$$


Coeficiente de aprendizaje (α)

$$\theta_1 := \theta_1 - \alpha \frac{\partial}{\partial \theta_1} J(\theta_1)$$

Si α es muy pequeño, el descenso por el gradiente es lento.

Si α es muy grande, el descenso por el gradiente puede saltar el mínimo. Y fallar en su propósito de converger a un mínimo global.

El valor de α puede cambiar a conveniencia, sin embargo aun cuando este estuviese fijo, lograra converger.



Descenso por el gradiente para la regresión lineal simple

repeat until convergence {

$$\theta_0 := \theta_0 - \alpha \frac{1}{m} \sum_{i=1}^m (h_{\theta}(x^{(i)}) - y^{(i)})$$

$$\theta_1 := \theta_1 - \alpha \frac{1}{m} \sum_{i=1}^m (h_{\theta}(x^{(i)}) - y^{(i)}) \cdot x^{(i)}$$

update
 θ_0 and θ_1
simultaneously

}

“Batch”, es una característica que considera que se deben utilizar todos los ejemplos de entrenamiento en cada paso.

REGRESION LINEAL MULTIVARIABLE

VARIAS CARACTERISTICAS

Size (feet ²)	Price (\$1000)	x_1 Tamaño (m ²)	x_2 Número dormitorios	x_3 Numero pisos	x_4 Antigüedad de la casa (años)	y Precio (\$1000)
x	y					
2104	460	2104	5	1	45	460
1416	232	1416	3	2	40	232
1534	315	1534	3	2	30	315
852	178	852	2	1	36	178
...	...	...	...	...	...	...

$$h_{\theta}(x) = \theta_0 + \theta_1 x_1 + \theta_2 x_2 + \theta_3 x_3 + \theta_4 x_4$$

37

Multiples características (variables)

Tamaño (m ²)	No habitaciones	No pisos	Edad de la casa (años)	Precio (\$1000)
2104	5	1	45	460
1416	3	2	40	232
1534	3	2	30	315
852	2	1	36	178
...	...	...	...	...

Notación:

n = número de características $x_1, x_2, x_3, \dots, x_n$

$x^{(i)}$ = entradas (características) i^{th} de entrenamiento ejemplo.

$x_j^{(i)}$ = valor de la característica j en el i^{th} ejemplo de entrenamiento.

Hipótesis regresión lineal multivariable.

Por conveniencia de la notación se establece $x_0 = 1$

$$x = \begin{bmatrix} x_0 \\ x_1 \\ x_2 \\ \vdots \\ x_n \end{bmatrix} \quad \theta = \begin{bmatrix} \theta_0 \\ \theta_1 \\ \theta_2 \\ \vdots \\ \theta_n \end{bmatrix} \quad \theta^T x = [\theta_0 \quad \theta_1 \quad \theta_2 \dots \theta_n] \begin{bmatrix} x_0 \\ x_1 \\ x_2 \\ \vdots \\ x_n \end{bmatrix}$$

$$h_{\theta}(x) = \theta_0 x_0 + \theta_1 x_1 + \theta_2 x_2 + \dots \theta_n x_n$$

$$h_{\theta}(x) = \theta^T x$$

Formulas regresión lineal multivariable

Hipótesis: $h_{\theta}(x) = \theta^T x = \theta_0 x_0 + \theta_1 x_1 + \theta_2 x_2 + \dots + \theta_n x_n$

Parámetros: $\theta_0, \theta_1, \dots, \theta_n$

Función de costo:

$$J(\theta_0, \theta_1, \dots, \theta_n) = \frac{1}{2m} \sum_{i=1}^m (h_{\theta}(x^{(i)}) - y^{(i)})^2$$

Repetir {

$$\theta_j := \theta_j - \alpha \frac{\partial}{\partial \theta_j} J(\theta_0, \dots, \theta_n)$$

} (actualiza simultaneamente cada $j = 0, \dots, n$)

Descenso por el gradiente regresión lineal multivariable

Previamente ($n=1$):

Repetir {

$$\theta_0 := \theta_0 - \alpha \frac{1}{m} \sum_{i=1}^m (h_{\theta}(x^{(i)}) - y^{(i)}) \underbrace{\frac{\partial}{\partial \theta_0} J(\theta)}$$

$$\theta_1 := \theta_1 - \alpha \frac{1}{m} \sum_{i=1}^m (h_{\theta}(x^{(i)}) - y^{(i)}) x^{(i)}$$

(se actualiza simultaneamente θ_0, θ_1)

}

Nuevo algoritmo: ($n \geq 1$)

Repetir {

$$\theta_j := \theta_j - \alpha \frac{1}{m} \sum_{i=1}^m (h_{\theta}(x^{(i)}) - y^{(i)}) x_j^{(i)}$$

(actualiza simultaneamente θ_j
para $j = 0, \dots, n$)

}

$$\theta_0 := \theta_0 - \alpha \frac{1}{m} \sum_{i=1}^m (h_{\theta}(x^{(i)}) - y^{(i)}) x_0^{(i)}$$

$$\theta_1 := \theta_1 - \alpha \frac{1}{m} \sum_{i=1}^m (h_{\theta}(x^{(i)}) - y^{(i)}) x_1^{(i)}$$


$$\theta_2 := \theta_2 - \alpha \frac{1}{m} \sum_{i=1}^m (h_{\theta}(x^{(i)}) - y^{(i)}) x_2^{(i)}$$

Escalado de características

Idea: Asegurar que las características estén en una escala similar.

E.g. x_1 = tamaño (0-2000 m²)


x_2 = número de habitaciones (1-5)



$$x_1 = \frac{\text{Tamaño (m}^2\text{)}}{2000}$$

$$x_2 = \frac{\text{Número de habitaciones}}{5}$$

$$0 \leq x_1 \leq 1 \quad 0 \leq x_2 \leq 1$$



Escalado de características

Obtener cada característica en aproximadamente un rango. $-1 \leq x_i \leq 1$

$x_0 = 1$ $0 \leq x_1 \leq 3$ ✓ $-2 \leq x_2 \leq 0.5$ ✓ $-100 \leq x_3 \leq 100$ ✗ $-0.0001 \leq x_4 \leq 0.0001$ ✗		$-3 \text{ to } 3$ ✓ $-\frac{1}{5} \text{ to } \frac{1}{5}$ ✓
--	--	--

Normalización media

$$x_i = \frac{x_i - \mu_i}{\sigma_i}$$

Donde μ_i es el promedio de los valores de la característica i , σ_i es la desviación estándar, considerada como la diferencia del mayor valor – menor valor entre los valores de la característica i .

Reemplazar x_i con $x_i - \mu_i$ para que las funciones tengan una media de aproximadamente cero (No aplicar a $x_0 = 1$).

$$x_1 = \frac{\text{size} - 1000}{2000}$$

$$x_2 = \frac{\text{\#bedrooms} - 2}{5}$$

$$-0.5 \leq x_1 \leq 0.5, -0.5 \leq x_2 \leq 0.5$$


Descenso por el gradiente

$$\theta_j := \theta_j - \alpha \frac{\partial}{\partial \theta_j} J(\theta)$$

"Depuración": cómo asegurarse de que el descenso de gradiente funciona correctamente.

Como elegir un coeficiente de aprendizaje adecuado α

Asegurar que el descenso por el gradiente funcione correctamente




Ejemplo de testeo de convergencia automática:

Es convergente si $J(\theta)$ decrete por lo menos 10^{-3} en una iteración.

30, 3000, 3,000,000

Asegurar que el descenso por el gradiente funcione correctamente



- Para un suficiente pequeño α , $J(\theta)$ debe decrecer en cada iteración.
- Pero si α es muy pequeño, el descenso por el gradiente puede converger lentamente.

Resumen

Si alfa es muy pequeño: convergencia lenta.

Si alfa es muy grande la función de costo no decrece en cada iteración, no converge

Para elegir alfa, ensayar con:

..., **0.001**, 0.003, **0.01**, 0.03, **0.1**, 0.3, **1**, ...

Predicción del precio de las casas

$$h_{\theta}(x) = \theta_0 x_0 + \theta_1 x_1 + \theta_2 x_2$$

$$h_{\theta}(x) = \theta_0 + \theta_1 * \text{frente} + \theta_2 * \text{fondo}$$


$$x = \text{frente} * \text{fondo}$$

$$h_{\theta}(x) = \theta_0 + \theta_1 x$$

$$h_{\theta}(x) = \theta^T x$$



Regresión polinómica



$$h_{\theta}(x) = \theta_0 + \theta_1 x_1 + \theta_2 x_2 + \theta_3 x_3$$


$$= \theta_0 + \theta_1(\text{size}) + \theta_2(\text{size})^2 + \theta_3(\text{size})^3$$

$$x_1 = (\text{size})$$

$$x_2 = (\text{size})^2$$

$$x_3 = (\text{size})^3$$

Elegir tipo de características




Descenso por el gradiente

Intuición: si 1D ($\theta \in \mathbb{R}$)

→ $J(\theta) = a\theta^2 + b\theta + c$

$\frac{\partial}{\partial \theta} J(\theta) = \dots \stackrel{\text{set}}{=} 0$

Solve for θ



$$\theta \in \mathbb{R}^{n+1} \quad J(\theta_0, \theta_1, \dots, \theta_m) = \frac{1}{2m} \sum_{i=1}^m (h_{\theta}(x^{(i)}) - y^{(i)})^2$$

$$\frac{\partial}{\partial \theta_j} J(\theta) = \dots = 0 \quad (\text{for every } j)$$

Solve for $\theta_0, \theta_1, \dots, \theta_n$

Ecuación de la normal

	Size (feet ²)	Number of bedrooms	Number of floors	Age of home (years)	Price (\$1000)
x_0	x_1	x_2	x_3	x_4	y
1	2104	5	1	45	460
1	1416	3	2	40	232
1	1534	3	2	30	315
1	852	2	1	36	178

$$X = \begin{bmatrix} 1 & 2104 & 5 & 1 & 45 \\ 1 & 1416 & 3 & 2 & 40 \\ 1 & 1534 & 3 & 2 & 30 \\ 1 & 852 & 2 & 1 & 36 \end{bmatrix} \quad y = \begin{bmatrix} 460 \\ 232 \\ 315 \\ 178 \end{bmatrix}$$

$$\theta = (X^T X)^{-1} X^T y$$

Ejemplo: m = 5

	Size (feet ²)	Number of bedrooms	Number of floors	Age of home (years)	Price (\$1000)
x_0	x_1	x_2	x_3	x_4	y
1	2104	5	1	45	460
1	1416	3	2	40	232
1	1534	3	2	30	315
1	852	2	1	36	178
1	3000	4	1	38	540

$$X = \begin{bmatrix} 1 & 2104 & 5 & 1 & 45 \\ 1 & 1416 & 3 & 2 & 40 \\ 1 & 1534 & 3 & 2 & 30 \\ 1 & 852 & 2 & 1 & 36 \\ 1 & 3000 & 4 & 1 & 38 \end{bmatrix} \quad y = \begin{bmatrix} 460 \\ 232 \\ 315 \\ 178 \\ 540 \end{bmatrix}$$

$$\Theta = (X^T X)^{-1} X^T y$$

m ejemplos de entrenamiento y n características

Descenso por el gradiente

- Se requiere elegir el coeficiente de aprendizaje α
- Se requiere muchas iteraciones
- Trabaja muy bien aun cuando n es grande

$$n = 10^6$$

Ecuación de la normal

- No requiere elegir el coeficiente de aprendizaje α
- No necesita iterar.
- Necesita calcular:
 $(X^T X)^{-1}$ $\frac{n \times n}{O(n^3)}$
- Lento si n es muy grande

$$n = 100$$

$$n = 1000$$


$$n = 10000$$

Ecuación de la normal y la no invertibilidad

- Este es un concepto avanzado
- La ecuación de la normal es: $\theta = (X^T X)^{-1} X^T y$
- Que sucede si $X^T X$ no se podría invertir?
- Hay matrices que se pueden invertir y otras que no se pueden invertir, estas son matrices singulares o degeneradas.
- Esto ocurre muy rara vez.
- Generalmente hay dos casos comunes:
 - La primera causa es que, de alguna manera, en el problema de aprendizaje tiene características redundantes. Por ejemplo si trata de predecir precios de casa y si x_1 es el tamaño de un casa en metros cuadrados y x_2 es el tamaño en pies cuadrados. Como 1 m cuadrado es igual a 3.28 pies, $x_1 = (3.28) * x_2$, de manera que si dos características están relacionadas por una ecuación como la anterior esa matriz no es invertible.
 - La segunda causa se debe a que cuando se entrena un algoritmo con muchas características ($m < n$)

REGRESIÓN LOGÍSTICA

Como se desarrolla un problema de clasificación?



El umbral del clasificador $h_{\theta}(x)$ en 0.5:

Si $h_{\theta}(x) \geq 0.5$, predice "y = 1"

Si $h_{\theta}(x) < 0.5$, predice "y = 0"

59

Otros aspectos relacionados a la regresión lineal aplicada a la clasificación

Clasificación:

Aplicando regresión lineal:

- $y = 0$ o $y = 1$
- $h(x)$ puede ser > 1 o < 0

Aplicando algoritmo de regresión logística:

$$0 \leq h_{\theta}(x) \leq 1$$

- Genera predicción de valores entre 0 y 1
- Se utiliza en procesos de clasificación

60

Representación de la hipótesis

Cual es la función que se utilizará para representar la hipótesis en un problema de clasificación.

Un modelo de regresión logística busca:


$$0 \leq h_{\theta}(x) \leq 1$$

$$h_{\theta}(x) = g(\theta^T x)$$

$$g(z) = \frac{1}{1+e^{-z}}$$

$$h_{\theta}(x) = \frac{1}{1+e^{-z}}$$

**Función sigmoidea
o función logística**



Interpretación de la salida de la hipótesis

$h_{\theta}(x)$ = estima la probabilidad que $y = 1$ sobre una nueva entrada x .

Ejemplo: Si $x = \begin{bmatrix} x_0 \\ x_1 \end{bmatrix} = \begin{bmatrix} 1 \\ \text{tumorSize} \end{bmatrix}$

$$h_{\theta}(x) = 0.7$$

El paciente tiene el 70% de probabilidad de que el tumor sea maligno

$$h_{\theta}(x) = P(y=1|x, \theta)$$

Probabilidad de que $y = 1$, dado un x parametrizado por θ .

$$P(y = 0|x; \theta) + P(y = 1|x; \theta) = 1$$

$$P(y = 0|x; \theta) = 1 - P(y = 1|x; \theta)$$

Representación de la hipótesis para la regresión logística

Decisión de límites, esto da mas claridad de lo que la hipótesis de la regresión logística esta computando.

En la regresión logística:

$$h_{\theta}(x) = g(\theta^T x)$$

$$g(z) = \frac{1}{1+e^{-z}}$$

Asumimos:

predecir " $y = 1$ " si $h_{\theta}(x) \geq 0.5$

predecir " $y = 0$ " si $h_{\theta}(x) < 0.5$

63


Decisión de límites

Dado:

- $h_{\theta}(x) = g(\theta_0 + \theta_1 x_1 + \theta_2 x_2)$

Predecir " $y = 1$ " si $-3 + x_1 + x_2 \geq 0$

- $x_1 + x_2 = 3$
- $\theta^T x$
- $x_1 + x_2 \geq 3$



64

Decisión de límites no lineales

Dado un conjunto de entrenamiento como el siguiente:

Como puede el algoritmo de regresión logística, ajustarse a este tipo de datos

Como en el caso de la regresión lineal simple o polinómica, se puede agregar grado a la ecuación de la hipótesis.

$$h_{\theta}(x) = g(\theta_0 + \theta_1 x_1 + \theta_2 x_2 + \theta_3 x_1^2 + \theta_4 x_2^2)$$

Asumiendo:

$$\theta_0 = -1, \theta_1 = 0, \theta_2 = 0, \theta_3 = 1, \theta_4 = 1$$

Predecir, $y = 1$ si $-1 + 1x_1^2 + 1x_2^2$


$$x_1^2 + x_2^2 \geq 1$$

La decisión del límite, no es una propiedad de los datos de entrenamiento, sino de la función de hipótesis y los parámetros.

Polinomios mas complejos:

$$h_{\theta}(x) = g(\theta_0 + \theta_1 x_1 + \theta_2 x_2 + \theta_3 x_1^2 + \theta_4 x_2^2 + \theta_5 x_1^2 x_2^2 + \theta_6 x_1^3 x_2 \dots)$$

Generan figuras y límites mas complejos de identificar.



65

Función de costo

Como se consigue obtener los parámetros theta, para la regresión logística?

Se define el objetivo de optimización o la función de costo que se utilizara para ajustar los parámetros theta.

Dado el conjunto de entrenamiento:

- $\{(x^{(1)}, y^{(1)}), (x^{(2)}, y^{(2)}), \dots, (x^{(m)}, y^{(m)})\}$
- Con m ejemplos

$$x \in \begin{bmatrix} x_0 \\ x_1 \\ \dots \\ x_n \end{bmatrix} \quad x_0 = 1, y \in \{0, 1\}$$

$$h_{\theta}(x) = \frac{1}{1 + e^{-\theta^T x}}$$

Como se calcula los parámetros θ ?


66

Problema con la función de costo de la regresión lineal aplicado a la regresión logística

En regresión lineal, la función de costo es:

$$J(\theta) = \frac{1}{m} \sum_{i=1}^m \frac{1}{2} (h_{\theta}(x^{(i)}) - y^{(i)})^2$$

$$\text{Cost}(h_{\theta}(x^{(i)}), y^{(i)}) = \frac{1}{2} (h_{\theta}(x^{(i)}) - y^{(i)})^2$$



67

Función de costo para la regresión logística

$$\text{Cost}(h_{\theta}(x), y) = \begin{cases} -\log(h_{\theta}(x)) & \text{if } y = 1 \\ -\log(1 - h_{\theta}(x)) & \text{if } y = 0 \end{cases}$$

Cost = 0 if $y = 1, h_{\theta}(x) = 1$

But as $h_{\theta}(x) \rightarrow 0$
Cost $\rightarrow \infty$

Captures intuition that if $h_{\theta}(x) = 0$,
(predict $P(y = 1|x; \theta) = 0$), but $y = 1$,
we'll penalize learning algorithm by a very
large cost.

$$\begin{aligned} \text{Cost}(h_{\theta}(x), y) &= 0 \text{ if } h_{\theta}(x) = y \\ \text{Cost}(h_{\theta}(x), y) &\rightarrow \infty \text{ if } y = 0 \text{ and } h_{\theta}(x) \rightarrow 1 \\ \text{Cost}(h_{\theta}(x), y) &\rightarrow \infty \text{ if } y = 1 \text{ and } h_{\theta}(x) \rightarrow 0 \end{aligned}$$

68

Descenso por el gradiente aplicado a la regresión logística

$$J(\theta) = \frac{1}{m} \sum_{i=1}^m \text{Cost}(h_{\theta}(x^{(i)}), y^{(i)})$$

$$\text{Cost}(h_{\theta}(x), y) = \begin{cases} -\log(h_{\theta}(x)) & \text{if } y = 1 \\ -\log(1 - h_{\theta}(x)) & \text{if } y = 0 \end{cases}$$

Note: $y = 0$ or 1 always

$$\begin{aligned} J(\theta) &= \frac{1}{m} \sum_{i=1}^m \text{Cost}(h_{\theta}(x^{(i)}), y^{(i)}) \\ &= -\frac{1}{m} \left[\sum_{i=1}^m y^{(i)} \log h_{\theta}(x^{(i)}) + (1 - y^{(i)}) \log (1 - h_{\theta}(x^{(i)})) \right] \end{aligned}$$

$$h = g(X\theta)$$

$$J(\theta) = \frac{1}{m} \cdot \left(-y^T \log(h) - (1 - y)^T \log(1 - h) \right) \quad \text{Versión vectorizada}$$

Para ajustar los parámetros theta

$$\min_{\theta} J(\theta)$$

Para hacer una predicción dado un nuevo valor de x

$$h_{\theta}(x) = \frac{1}{1 + e^{-\theta^T x}}$$

$$J(\theta) = -\frac{1}{m} \left[\sum_{i=1}^m y^{(i)} \log h_{\theta}(x^{(i)}) + (1 - y^{(i)}) \log (1 - h_{\theta}(x^{(i)})) \right]$$

Se busca: $\min_{\theta} J(\theta)$

repetir {

$$\theta_j := \theta_j - \alpha \frac{\partial}{\partial \theta_j} J(\theta)$$

} (actualizando simultaneamente todos los θ_j)

Repeat {

$$\theta_j := \theta_j - \alpha \sum_{i=1}^m (h_{\theta}(x^{(i)}) - y^{(i)}) x_j^{(i)}$$

} (simultaneously update all θ_j)

Versión vectorizada $\theta := \theta - \frac{\alpha}{m} X^T (g(X\theta) - \vec{y})$

Algoritmos de optimización avanzada

Con estas ideas se pretende tomar la regresión logística, y hacerla funcionar mas rápidamente que utilizando el descenso por el gradiente.

Mas cantidades de datos

Mas características

Algoritmo de optimización

A partir de la función de costo $J(\theta)$ se quiere $\min_{\theta} J(\theta)$

Dado Θ , se considera el código que computa

$$\frac{\partial}{\partial \theta_j} J(\theta) \quad (\text{para } j = 0, 1, \dots, n)$$

Descenso por el gradiente

Repetir{

$$\theta_j := \theta_j - \alpha \frac{\partial}{\partial \theta_j} J(\theta)$$

}

Algoritmos de optimización

- Descenso por el gradiente
- Gradiente conjugado
- BFGS
- L-BFGS

73

Ventajas y desventajas de algoritmos de optimización

Ventajas

- No se necesita asignar manualmente un valor para α
- Son mas rápidos que el descenso por el gradiente

Desventajas

- Mas complejos

74

Ejemplo

$$\theta = \begin{bmatrix} \theta_1 \\ \theta_2 \end{bmatrix}$$

$$J(\theta) = (\theta_1 - 5)^2 + (\theta_2 - 5)^2$$

$$\frac{\partial}{\partial \theta_1} J(\theta) = 2(\theta_1 - 5)$$

$$\frac{\partial}{\partial \theta_2} J(\theta) = 2(\theta_2 - 5)$$

75

Clasificación multiclase

One vs. All


Algoritmo de clasificación One-vs-All

Ejemplos de clasificación multiclase


- Carpetas de correo electrónico / etiquetado: Trabajo, amigos, familia, Hobby
- Diagramas médicos: No enfermo, frío, gripe.
- Clima: Soleado, Nublado, Lluvia, Nieve.

76

Clasificación binaria:




Clasificación multi-clase



77

One-vs-all (one-vs-rest):



$$h_{\theta}^{(i)}(x) = P(y = i|x; \theta) \quad (i = 1, 2, 3)$$

78


Entrenar un clasificador de regresión logística
probabilidad de que $y = 1$.

para cada clase i , para predecir la
 $h_{\theta}^{(i)}(x)$

Sobre una nueva entrada para x , para hacer la predicción, se debe tomar la clase i que maximiza

$$\max_i h_{\theta}^{(i)}(x)$$

79




Machine Learning

Regularización


El problema de sobre
ajuste (overfitting)

Ejemplo: Regresión lineal (precio de casas)




$$\theta_0 + \theta_1 x$$

Underfit – High bias
Subajuste



$$\theta_0 + \theta_1 x + \theta_2 x^2$$

Correcto




$$\theta_0 + \theta_1 x + \theta_2 x^2 + \theta_3 x^3 + \theta_4 x^4$$

Overfit – High variance
Sobreajuste

Overfitting: Si se tienen muchas características, la hipótesis aprendida puede ajustar el conjunto de datos de entrenamiento muy bien ($J(\theta) = \frac{1}{2m} \sum_{i=1}^m (h_{\theta}(x^{(i)}) - y^{(i)})^2 \approx 0$), pero puede fallar al generalizar nuevos ejemplos (predecir precios sobre nuevos ejemplos).


Ejemplo: Regresión logística



$$h_{\theta}(x) = g(\theta_0 + \theta_1 x_1 + \theta_2 x_2)$$


(g = sigmoid function)

Underfit – High bias
Subajuste



$$g(\theta_0 + \theta_1 x_1 + \theta_2 x_2 + \theta_3 x_1^2 + \theta_4 x_2^2 + \theta_5 x_1 x_2)$$

Correcto



$$g(\theta_0 + \theta_1 x_1 + \theta_2 x_1^2 + \theta_3 x_1^2 x_2 + \theta_4 x_1^2 x_2^2 + \theta_5 x_1^2 x_2^3 + \theta_6 x_1^3 x_2 + \dots)$$

Overfit – High variance
Sobreajuste

Abordar el sobreajuste

X1 = Tamaño de la casa

X2 = Numero de dormitorios

X3 = Numero de pisos

X4 = ingreso promedio en el vecindario

X5 = Tamaño de la cocina


.

.

.

.


X100 ...



Como solucionamos el sobreajuste

Opciones:

1. Reducir el numero de características.
 - Elegir manualmente las características que se conservaran o eliminaran.
 - Algoritmos de selección de modelos
2. Regularización.
 - Mantener todas las características, pero reducir la magnitud / valores de los parámetros θ_j .
 - Funciona bien cuando tenemos muchas características, cada una de las cuales contribuye un poco a predecir y




Machine Learning

Regularization

Cost function

Regularización – función de costo



Supongamos que penalizamos y hacemos muy pequeño. θ_3 θ_4

$$\rightarrow \min_{\theta} \frac{1}{2m} \sum_{i=1}^m (h_{\theta}(x^{(i)}) - y^{(i)})^2 + 1000 \theta_3^2 + 1000 \theta_4^2$$

$\theta_3 \approx 0$ $\theta_4 \approx 0$

Regularización

Valores pequeños para los parámetros $\theta_0, \theta_1, \dots, \theta_n$

- Hipotesis "Simple"
- Menos propenso al sobreajuste

$$\rightarrow \boxed{\theta_3, \theta_4} \quad \uparrow \approx 0$$

Casas:

- Características: $x_1, x_2, \dots, x_{100}$
- Parámetros: $\theta_0, \theta_1, \theta_2, \dots, \theta_{100}$

$$J(\theta) = \frac{1}{2m} \left[\sum_{i=1}^m (h_{\theta}(x^{(i)}) - y^{(i)})^2 + \lambda \sum_{j=1}^n \theta_j^2 \right]$$


Handwritten notes: Below the equation, $\theta_0, \theta_1, \theta_2, \dots, \theta_{100}$ are written with some terms crossed out. A red arrow points from the regularization term to the θ_j terms.

Regularization.

$$\rightarrow J(\theta) = \frac{1}{2m} \left[\sum_{i=1}^m (h_{\theta}(x^{(i)}) - y^{(i)})^2 + \lambda \sum_{j=1}^n \theta_j^2 \right]$$

Handwritten notes: A blue bracket under the first sum is labeled with an arrow. A pink bracket under the second sum is labeled "regularization parameter".

$$\min_{\theta} J(\theta)$$



En una regresión lineal regularizada, se elige θ para minimizar

$$J(\theta) = \frac{1}{2m} \left[\sum_{i=1}^m (h_{\theta}(x^{(i)}) - y^{(i)})^2 + \lambda \sum_{j=1}^n \theta_j^2 \right]$$


Que pasa si se establece un valor de λ extremadamente grande (talvez demasiado grande para el problema, como $\lambda = 10^{10}$)?

- El algoritmo funciona bien; la configuración de λ muy grande no puede dañarlo.
- El algoritmo no elimina el sobreajuste.
- El algoritmo da como resultado subajuste. (No se ajusta bien incluso a los datos de entrenamiento).
- El descenso por el gradiente falla en su convergencia.

En una regression lineal regularizada, se elige θ para minimizar

$$J(\theta) = \frac{1}{2m} \left[\sum_{i=1}^m (h_{\theta}(x^{(i)}) - y^{(i)})^2 + \lambda \sum_{j=1}^n \theta_j^2 \right]$$

Que pasa si se establece un valor de λ extremadamente grande (talvez demasiado grande para el problema, como $\lambda = 10^{10}$)?



$$\begin{aligned} \theta_1, \theta_2, \theta_3, \theta_4 \\ \theta_1 \approx 0, \theta_2 \approx 0 \\ \theta_3 \approx 0, \theta_4 \approx 0 \end{aligned}$$

$$h_{\theta}(x) = \theta_0$$

$$\theta_0 + \cancel{\theta_1 x} + \cancel{\theta_2 x^2} + \cancel{\theta_3 x^3} + \cancel{\theta_4 x^4}$$

Regresion lineal regularizada

$$J(\theta) = \frac{1}{2m} \left[\sum_{i=1}^m (h_{\theta}(x^{(i)}) - y^{(i)})^2 + \lambda \sum_{j=1}^n \theta_j^2 \right]$$

$$\min_{\theta} J(\theta)$$

Descenso por el gradiente

θ_0

$\theta_1, \theta_2, \dots, \theta_n$

Repetir {

$$\rightarrow \theta_0 := \theta_0 - \alpha \frac{1}{m} \sum_{i=1}^m (h_{\theta}(x^{(i)}) - y^{(i)}) x_0^{(i)}$$

$\frac{\partial}{\partial \theta_0} J(\theta)$

$$\rightarrow \theta_j := \theta_j - \alpha \left[\frac{1}{m} \sum_{i=1}^m (h_{\theta}(x^{(i)}) - y^{(i)}) x_j^{(i)} - \frac{\lambda}{m} \theta_j \right]$$

$(j = 1, 2, 3, \dots, n)$

$$\theta_j := \theta_j (1 - \alpha \frac{\lambda}{m}) - \alpha \frac{1}{m} \sum_{i=1}^m (h_{\theta}(x^{(i)}) - y^{(i)}) x_j^{(i)}$$

$\rightarrow J(\theta)$

$$1 - \alpha \frac{\lambda}{m} < 1$$

0.99

$\theta_j \times 0.99$

θ_j^2

Ecuación de la Normal

$$\begin{aligned}
 \underline{X} &= \begin{bmatrix} (x^{(1)})^T \\ \vdots \\ (x^{(m)})^T \end{bmatrix} \quad \leftarrow \text{ } m \times (n+1) \\
 y &= \begin{bmatrix} y^{(1)} \\ \vdots \\ y^{(m)} \end{bmatrix} \quad \mathbb{R}^m \\
 &\rightarrow \min_{\theta} J(\theta) \quad \frac{\partial}{\partial \theta_j} J(\theta) \stackrel{\text{set}}{=} 0 \quad \text{ } \\
 \Rightarrow \theta &= \left(X^T X + \lambda \underbrace{\begin{bmatrix} 0 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & 0 & 1 \end{bmatrix}}_{(n+1) \times (n+1)} \right)^{-1} X^T y \\
 &\quad \text{e.g. } n=2 \quad \begin{bmatrix} 0 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & 0 & 1 \end{bmatrix}
 \end{aligned}$$


No inversibilidad (optional/advanced).

Suppose $m \leq n$, $\leftarrow$
 (#examples) (#features)

$$\theta = \underbrace{(X^T X)^{-1}}_{\text{non-invertible / singular}} X^T y \quad \begin{matrix} \text{pinv} \\ \text{inv} \end{matrix}$$

If $\lambda > 0$,

$$\theta = \left(X^T X + \lambda \underbrace{\begin{bmatrix} 0 & & & \\ & 1 & & \\ & & 1 & \\ & & & \ddots \\ & & & & 1 \end{bmatrix}}_{\text{invertible}} \right)^{-1} X^T y$$




Machine Learning

Regularización

Regresión logística regularizada

Regresión logística regularizada.



$$h_{\theta}(x) = g(\theta_0 + \theta_1 x_1 + \theta_2 x_1^2 + \theta_3 x_1^2 x_2 + \theta_4 x_1^2 x_2^2 + \theta_5 x_1^2 x_2^3 + \dots)$$

Función de costo:

$$J(\theta) = - \left[\frac{1}{m} \sum_{i=1}^m y^{(i)} \log h_{\theta}(x^{(i)}) + (1 - y^{(i)}) \log(1 - h_{\theta}(x^{(i)})) \right]$$


```
gradient(n+1) = [code to compute  $\frac{\partial}{\partial \theta_n} J(\theta)$ ];
```

Segmentación (Clustering)

Objetivo: Organizar en grupos homogéneos



99

Ejemplos de segmentación

- Identificar áreas de similar topografía
- Buscar tipologías de clientes
- Entre otros mas ...

100

Asociación

Objetivo: Identificación de eventos que ocurren juntos o en secuencia



101

Ejemplos de asociación

- Recomendaciones de compra basado en historial de compras y navegación
- Venta de artículos que se suelen vender juntos.
- Entre otros mas ...

102